

Reliable and Trustworthy Artificial Intelligence Assignment #4

2023480022 이현오

1. A description of your model, dataset, and verification property.

사용한 모델: 3-layer Fully Connected Neural Network(75%의 정확도)

Input: 784 units

Hidden Layers: 512->64->32

Output: 10 classes

사용된 데이터 셋: Fashion-MNIST

Verification property: 원본 이미지 x 에 대한 L_{∞} distance 내의 모든 변동 입력에 대해 0.05범위에서 동일한 클래스를 유지하는 지 검증.

2. The results and their interpretation

총 검증 소요 시간: 132.51 초

검증 정확도: 8.0%

반례 발견 : 91 개

검증 완료 : 8 개

타임아웃 : 1 개

75%의 정확도를 가진 모델임에도 검증이 완료된 모델이 8개 밖에 되지 않고, 타임아웃이 1개인 것을 보아 단 시간에 적대적 예제를 찾아내어 모델이 매우 취약하다는 것을

알 수 있겠다. 또한 이러한 취약성을 보이는 것은 모델이 3 layer로 구성된 작은 모델이기 때문에 아주 미세한 변화에도 출력이 크게 바뀌기 때문으로 추측된다.

3. A comparison between α , β -Crown and Marabou (if you used the same model): differences in speed, scalability, ease of use, and supported features.

입실론 0.05에서 α , β -Crown은 132.51초 Marabou는 736초의 시간이 걸렸다. α , β -Crown은 100개의 데이터를 모두 돌지만 Marabou는 반례를 하나 찾으면 종료한다. 둘 다 수학적 검증을 사용하지만 후자는 SMT solver 기반이고 전자는 경사하강법과 Branch and Bound를 사용한다.

4. A brief discussion of α , β -Crown's strengths and limitations based on your experience.

α , β -Crown은 모든 연산 과정에서 미분이 가능하기 때문에 GPU사용이 가능하다는 점이 큰 장점이고 yaml 설정 파일과 pytorch기반으로 작동하여 커스텀이 비교적 쉽다는 장점이 존재한다. 하지만 NotImplementedError: Dataset not supported in this file! Please customize load_verification_dataset() function in utils.py. 와 같은 오류의 경우 load_verification_dataset()이 utils.py가 아닌 loading.py에 존재하는 함수로 업데이트 되었지만 에러 메시지가 업데이트 되지 않았다. 이러한 잘못된 안내는 사용자로 하여금 혼란을 줄 수 있고 피로도를 유발한다는 것이 단점으로 작용한다.